

좌측 손 X-ray 뼈나이 예측 AI 프로젝트


조성완 | AI · Data Developer

Python · PyTorch · Computer Vision · Data Analysis


좌측 손 X-ray 뼈나이 예측 AI

손 영역 표준화 전처리와 ConvNeXt+LDL 기반 뼈나이 예측

! Problem | 의사의 수기 판독은 시간과 일관성 측면의 한계가 있어, 손 X-ray 기반 뼈나이 예측 AI 모델을 개발함



예측 시스템 화면



X-ray와 성별 정보를 입력해 예측 뼈나이를 출력

Key Insight

1. 문제 발견

단순 명암 보정 중심 전처리만으로는
성능 개선 폭이 제한적이었음

↓

2. 원인 분석

손 위치·크기·방향 편차로 인해
모델이 불필요한 변동성을 학습

↓

3. 개선 방향

Detection·Segmentation 기반
입력 표준화 파이프라인 고도화

내부 Test 결과

MAE
4.24개월

RMSE
5.41개월

R²
0.984

01. Dataset & Problem Analysis

학습 데이터 구성과 원본 X-ray에서 관찰된 입력 편차

Dataset: RSNA Pediatric Bone Age Challenge

Input	Target	Metadata	Original Dataset Split
Left Hand X-ray	Bone Age (months)	Sex	Train 12,611 / Val 1,425 / Test 200

1 Scale Variation

손 크기 / 촬영 범위 편차



촬영 거리 및 범위 차이로
손의 크기 비율이 달라짐

2 Rotation Variation


손 방향 / 회전 편차



촬영 자세에 따라 손이 회전되어
다양한 방향으로 입력됨

3 Position Variation

손 위치 편차



촬영 위치 차이로 인해
영상 내 손의 중심 위치가 달라짐

Problem

손의 위치·크기·방향 등 촬영 조건에 따른 편차로 인해
뼈나이와 무관한 불필요한 변동성이 모델에 학습될 수 있음



Goal

손 영역을 자동 추출·정렬하여 입력 형태를 표준화하고
뼈의 형태적 특징에 집중할 수 있는 입력을 구성

02. Hand Detection & Segmentation

손 영역 검출과 분할 모델을 직접 학습하여, 이후 단계의 정렬과 표준화를 위한 기반을 구축


1 Hand Detection (Bounding Box)

YOLOX-S Train 119 / Val 39

- 전체 X-ray에서 손 영역을 자동으로 검출
- 빠르고 가벼운 검출 모델로 ROI 후보를 정확히 추출



라벨링



YOLOX-S Detection

Detection Performance

99.4%
mAP@0.5:0.95

2 Hand Segmentation (Pixel-wise Mask)

DeepLabV3-MobileNetV3-Large Train 135 / Val 44

- Detection으로 추출한 ROI를 입력으로 손 영역을 픽셀 단위로 분할
- 손의 실제 윤곽 마스크를 생성하여 이후 정렬(PCA) 기준으로 사용



라벨링



Predicted Mask (Segmentation)

Segmentation Performance

98.7% Dice
97.3% IoU

03. Spatial Input Standardization

Segmentation Mask 기반 방향 정렬과 512x512 입력 표준화


핵심 흐름 (Pipeline)

Detection (YOLOX-S) → Segmentation (DeepLabV3)

→ PCA Alignment → 512x512 Input

1 Hand Detection (Bounding Box)

YOLOX-S로 손 영역 검출 및 ROI 추출




원본 X-ray

ROI Crop

2 Segmentation & PCA Alignment

DeepLabV3-MobileNetV3-Large로 분할 후 PCA 기반 방향 정렬



Segmentation
Mask

PCA로 Mask의
주축 추정

주축이 수직이
되도록 회전 정렬

3 Final 512x512 Input

정렬된 ROI를 512x512로
리사이즈



512x512 Resize
+ Masked P1-P99
+ Background Removal

PCA Alignment 과정 (수학적 개요)

1. Mask의 모든 Foreground 픽셀 좌표 $\{(x_i, y_i)\}$ 수집
2. 공분산 행렬 Σ 계산
3. 고유값 분해($\Sigma = V\Lambda V^T$) 수행
4. 최대 고유값에 해당하는 고유벡터 → 주축(PC1)
5. 주축이 수직 방향이 되도록 회전 변환 적용



04. Preprocessing Experiments

입력 전처리 방식별 효과 비교

1 Original

원본 X-ray



촬영 조건에 따른
명암·대비 편차 존재

Validation MAE

5.845

Validation RMSE

8.155

2 CLAHE

국소 대비 향상



3 Global Histogram Equalization



Validation MAE

5.862

Validation RMSE

8.163

4 Top-hat



5 Percentile Normalization



Validation MAE

5.842






Validation RMSE

8.118

전처리 실험을 통해 단순 명암 보정의 한계를 확인 → 손 영역 기반 Masked Percentile + Background Removal 적용

05. Backbone Selection





다양한 CNN backbone을 동일 입력 조건에서 비교하여 최적의 모델을 선정

Xception	EfficientNetV2-S	ConvNeXt V1-Tiny	ConvNeXt V2-Tiny	ConvNeXt V2-Base
				
깊이 분리 합성곱 기반 전통적 CNN 구조	효율적인 스케일링과 Fused-MBConv 구조	현대화된 CNN 구조 (큰 커널, LayerNorm 등)	V2 개선 구조 (향상된 Block & Downsample)	V2 계열의 더 큰 모델 (더 높은 표현 능력)
Val MAE(개월) 6.583	Val MAE(개월) 6.490	Val MAE(개월) 6.397	Val MAE(개월) 6.311	Val MAE(개월) 6.310
Val RMSE(개월) 9.012	Val RMSE(개월) 8.830	Val RMSE(개월) 8.622	Val RMSE(개월) 8.634	Val RMSE(개월) 8.638

성능만 보면 ConvNeXt V2계열이 가장 우수했지만, 라이선스 및 활용 조건을 고려하여
최종 backbone은 ConvNext V1-Tiny로 선정

06. Final Architecture & Label Distribution Learning



ConvNeXt V1-Tiny와 성별 정보를 결합한 240-bin 뼈나이 분포 학습



본 프로젝트의 최종 모델은 ConvNeXt V1-Tiny backbone과 성별 정보를 결합하여, LDL 기반 240-bin 분포를 예측하고 기대값을 이용해 골연령(월)으로 변환합니다.

07. Structural Experiments / Experiment Journey

다양한 구조적 개선을 시도하며 성능을 점진적으로 향상시켜 최종 모델을 선정




✓ 핵심 결론: 구조 실험은 validation 기준으로 독립 비교했으며, 최종 모델 선택 후 held-out test를 1회 평가했다.

08. Final Performance - Internal Test (Final Model)

최종 모델의 내부 테스트 성능 (데이터 분포 유지)

Test Set Overview		
	Total Samples	197 cases
	Age Range (Target)	1 – 240 months
	Sex Distribution	Male 117 (59.4%) Female 80 (40.6%)
	Evaluation Protocol	Held-out Test Set (모델 선택 이후 1회 평가)



Overall Performance (Test Set)	
MAE (Mean Absolute Error)	4.245 months
RMSE (Root Mean Squared Error)	5.412 months
R ² (Coefficient of Determination)	0.9837
Bias (Mean Error)	+0.794 months
Median Absolute Error	3.279 months
P90 Absolute Error	8.688 months
P95 Absolute Error	10.452 months
Max Absolute Error	17.581 months
Absolute Error ≥ 20 months	0 cases


Performance by Bone-age Group				
Bone-age Group (Target, months)	N (cases)	MAE (months)	RMSE (months)	Bias (Mean Error) (months)
≤ 60	13	3.915	5.495	+2.205
61 – 96	30	6.169	7.029	+3.418
97 – 144	64	4.885	6.297	+1.336
> 144	90	3.195	3.885	-0.670
Overall	197	4.245	5.412	+0.794

Key Takeaways	
✓	전체 Test Set 기준 MAE 4.245개월, RMSE 5.412개월로 높은 정확도를 달성함
✓	R ² 0.9837로 실제 월령과 예측 월령이 매우 강한 상관관계를 보임
✓	전체 Bias는 +0.794개월로, 전반적으로 경미한 과대예측 경향이 존재
✓	어린 연령대(≤ 96개월)에서 과대예측 경향이 상대적으로 크며, 144개월 초과 구간에서는 근소한 과소예측 경향이 나타남
✓	모든 구간에서 안정적인 성능을 보이며, 큰 오차 없이 일관된 예측 성능을 유지함

* Bias(Mean Error) = Predicted Age – Actual Age (+: 과대예측, -: 과소예측)

09. Enterprise External Evaluation & Error Analysis

기업 외부 데이터(381건) 평가 및 성별 / 연령별 오차 분석을 통한 모델 일반화 성능 검증



기업 외부 평가(381건)에서 MAE 6.654개월, RMSE 8.808개월을 기록했습니다.
특히 남아와 저연령 구간에서 오차 및 과대예측 편향이 크게 나타나, 향후 **성별·연령 특화 보정**과 데이터 균형 개선이 중요함을 확인했습니다.

10. System Demo & My Role & Conclusion

개발한 뼈나이 예측 시스템과 담당 역할, 프로젝트 성과 및 향후 개선 방향



My Role

- 문제 정의 및 전체 설계**
 - 임상 요구사항 분석 및 문제 정의, 전체 파이프라인 설계
- 데이터 파이프라인 구축**
 - YOLO 기반 정렬/Segmentation, 전처리 파이프라인 구축 및 QC
- 모델 연구 및 개발**
 - 다양한 구조 실험 설계 및 구현 (LDL, CDF, Attention, ROI, Bias)
 - ConvNeXt 기반 최종 모델 개발 및 튜닝
- 평가 및 분석**
 - 내부/외부 평가 및 성별-연령별 오차 분석, 인사이트 도출
- 시스템 및 대시보드 구현**
 - 추론 시스템 및 대시보드 연동, 시각화 기능 구현

Project Achievements

- ✓ 높은 예측 정확도 달성
Internal Test MAE 4.24개월, RMSE 5.41개월, R^2 0.984
- ✓ 임상 활용 가능한 수준의 성능 확보
Enterprise External MAE 6.654개월, ± 12 개월 정확도 84.0%
- ✓ 성별/연령별 분석을 통한 주요 인사이트 도출
남아 저연령 과대예측 패턴 규명 및 개선 방향 제시
- ✓ 실서비스 구현 및 시연
웹 기반 예측 시스템 및 대시보드 개발 완료

Key Contributions

- YOLO Segmentation 기반 고품질 정렬/ROI 생성
손 영역 정밀 추출 및 일관된 입력 표준화 구현
- LDL + Bias Regularization 기반 최적 모델 개발
최종 모델 MAE 5.825개월 (Validation) 달성
- 다양한 구조적 실험을 통한 체계적 성능 개선
CDF, Attention, Local ROI, Fusion 등 유효성 검증
- 외부 데이터 검증 및 일반화 성능 확보
Enterprise 데이터로 모델 일반화 성능 검증 완료

Limitations & Future Work

한계점

- 남아 저연령(0-60개월) 과대예측 및 오차 여전히 큼
- 연령 불균형으로 저연령 데이터 비율이 낮음
- 외부 데이터 도메인 다양성 제한

향후 개선 방향

- 저연령 남아 보정 전략 강화 (연령/성별 특화 보정 모델)
- 더 많은 저연령 데이터 확보 및 도메인 확장
- 불확실성 추정 고도화 및 이상 사례 탐지 모듈 추가
- 멀티센터 데이터 기반 추가 검증 및 임상 적용 확대

본 프로젝트를 통해 임상 현장에서 신뢰할 수 있는 수부 뼈나이 예측 AI 모델과 시스템을 구현하였으며, 향후 연령/성별 특화 보정과 데이터 확장을 통해 **더욱 정확하고 공정한 모델로 발전시켜 나가겠습니다.**